

WebIR Term Project 第六組期末書面報告

314581006 林鼎翔、314581015 劉馨

一、簡介


本期末專題為醫療問答檢索任務，資料來源為衛福部台灣 e 院，文件集合包含 2000 年 8 月至 2025 年 12 月共 171,562 筆 QA pairs。每筆資料包含 ID、Question 與 Answer。任務目標是針對提供的醫療問題，從歷史問答資料中檢索出最相關的 Top-30 回答。系統需要同時考慮語意相似、關鍵字匹配與回答內容是否真正回答問題的需求。

二、評估方式與指標

每個 query 需要回傳 Top-30 ranking results，並透過 TREC Pooling Method 進行人工標註。標註等級包含 Relevant、Partial Relevant 與 Non-Relevant。評估指標包含 MAP@K、MRR、NDCG@K。我們在 Phase 2 的內部評估則使用 Phase 1 的 query 與人工標註結果，將其作為不同方法比較與參數調整依據，以 Mean Rank¹ 衡量我們方法好壞。

三、Phase 1 方法與結果分析

Phase 1 主要參考 ReFIT 方法²，方法架構圖（見圖一）如下，核心概念是在推論階段利用 reranker 的相關性回饋更新 query embedding，再使用更新後的 query embedding 進行第二次檢索。實作上，我們使用 Qwen3-Embedding-4B 作為 dense retriever，並使用 Qwen3-Reranker-4B 作為 reranker。先使用 dense retriever 取得 Top-100 候選文件，再由 reranker 算相關性分數，接著以 KL divergence 讓 retriever 的分布模仿 reranker 的分數分布，最後更新 query embedding 並進行第二次檢索。



圖一：ReFIT 方法架構圖

¹ Mean Rank 為我們方法在所有組別中的該指標平均排名。

² Revanth Gangi Reddy, Pradeep Dasigi, Md Arafat Sultan, Arman Cohan, Avirup Sil, Heng Ji, and Hannaneh Hajishirzi. 2025. A Large-Scale Study of Reranker Relevance Feedback at Inference. In Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '25). Association for Computing Machinery, New York, NY, USA, 3010 – 3014. <https://doi.org/10.1145/3726302.3730160>

在 Phase 1 結果中，我們的排名為最後一名（見表格一），從結果來看，ReFIT 在此任務中未能穩定提升檢索效果。可能原因是 ReFIT 主要改善 recall，但評估指標也重視排序品質；此外，更新 query embedding 可能使向量偏離原始問題意圖，導致檢索方向受到影響。因此，後續 Phase 2 改為避免直接更新 query embedding，並從檢索對象、模型組合、關鍵字檢索與排序優化等方向進行改進。

Team	MAP@10	MAP@30	MRR	NDCG@10	NDCG@30	Mean Rank
Team 3	0.7810 ⁽¹⁾	0.6766 ⁽¹⁾	0.9500 ⁽¹⁾	0.9147 ⁽¹⁾	0.8575 ⁽¹⁾	1
Team 7	0.7668 ⁽²⁾	0.5879 ⁽²⁾	0.9500 ⁽¹⁾	0.9050 ⁽²⁾	0.8057 ⁽²⁾	1.8
Team 9	0.5955 ⁽³⁾	0.4067 ⁽⁵⁾	0.9333 ⁽³⁾	0.7896 ⁽³⁾	0.6825 ⁽⁵⁾	2.8
Team 8	0.5950 ⁽⁴⁾	0.4383 ⁽⁴⁾	0.8750 ⁽⁴⁾	0.7865 ⁽⁴⁾	0.7048 ⁽⁴⁾	4
Team 4	0.5495 ⁽⁵⁾	0.4718 ⁽³⁾	0.8333 ⁽⁶⁾	0.7767 ⁽⁵⁾	0.7410 ⁽³⁾	5.5
Team 2	0.4521 ⁽⁷⁾	0.3917 ⁽⁶⁾	0.8500 ⁽⁵⁾	0.7080 ⁽⁶⁾	0.6718 ⁽⁶⁾	6
Team 1	0.4582 ⁽⁶⁾	0.3837 ⁽⁷⁾	0.6833 ⁽⁹⁾	0.6633 ⁽⁷⁾	0.6704 ⁽⁷⁾	7.2
Team 5	0.4260 ⁽⁸⁾	0.2823 ⁽⁹⁾	0.8833 ⁽⁶⁾	0.6443 ⁽⁹⁾	0.5724 ⁽⁹⁾	8.2
Team 6	0.4059 ⁽⁹⁾	0.3543 ⁽⁸⁾	0.7750 ⁽⁸⁾	0.6470 ⁽⁸⁾	0.6363 ⁽⁸⁾	8.2

表格一：Term Project Phase 1 Results

四、內部評估結果

根據 Phase 1 的結果分析，我們針對 Phase 1 的問題進行多組實驗，並使用 Phase 1 的人工標註結果進行內部實驗的評估，以決定要提交至 Phase 2 的最終方法。首先，我們去比較有無使用 ReFIT 的表現差異，結果顯示不更新 query embedding 的效果較佳，Mean Rank 從 8.2 改善為 6.8（見表格二）。

比較有無使用 ReFIT	MAP@10	MAP@30	MRR	NDCG@10	NDCG@30	Mean_rank
使用 ReFIT	0.4059	0.3543	0.7750	0.6470	0.6363	8.2
不使用 ReFIT	0.4531	0.2627	0.6167	0.6826	0.8443	6.8

表格二：有無 ReFIT 的實驗表格

接著比較不同模型組合，結果顯示 Qwen3-Embedding-4B 搭配 Qwen3-Reranker-4B 的整體表現較穩定（見表格三）。

比較不同模型組合	MAP@10	MAP@30	MRR	NDCG@10	NDCG@30	Mean_rank
Qwen3-Embedding-4B + Qwen3-Reranker-4B	0.4531	0.2627	0.6167	0.6826	0.8443	6.8
bge-m3 + Qwen3-Reranker-4B	0.4438	0.2512	0.6283	0.6769	0.8326	7.0
Qwen3-Embedding-4B + bge-reranker-v2-m3	0.3995	0.2553	0.7750	0.6513	0.8510	7.4
bge-m3 + bge-reranker-v2-m3	0.3197	0.2014	0.7000	0.6005	0.8087	7.4

表格三：不同模型組合的實驗表格

之後，我們調整檢索對象，將原本只使用 Question 改為使用 Question + Answer。結果顯示，加入 Answer 後能提供完整的語境，Mean Rank 從 6.8 改善為 6.2（見表格四）。

比較檢索對象	MAP@10	MAP@30	MRR	NDCG@10	NDCG@30	Mean_rank
檢索對象：問題	0.4531	0.2627	0.6167	0.6826	0.8443	6.8
檢索對象：問題+回覆	0.5267	0.2847	0.7218	0.7122	0.8509	6.2

表格四：檢索對象實驗比較表格

接著我們加入 BM25 關鍵字檢索，並與 Qwen dense retrieval 的結果取 union，再交由 Qwen reranker 重新排序。加入 BM25 後，Mean Rank 改善為 4.4（見表格五）。此結果顯示，醫療問答檢索不能只依賴語意相似度，關鍵字也很重要。

有無加入關鍵字檢索	MAP@10	MAP@30	MRR	NDCG@10	NDCG@30	Mean_rank
Retrieve: Qwen3-Embedding-4B	0.5267	0.2847	0.7218	0.7122	0.8509	6.2
Retrieve: BM25 union Qwen3-Embedding-4B	0.6322	0.3856	0.8533	0.7858	0.9119	4.4

表格五：有無關鍵字檢索的實驗表格

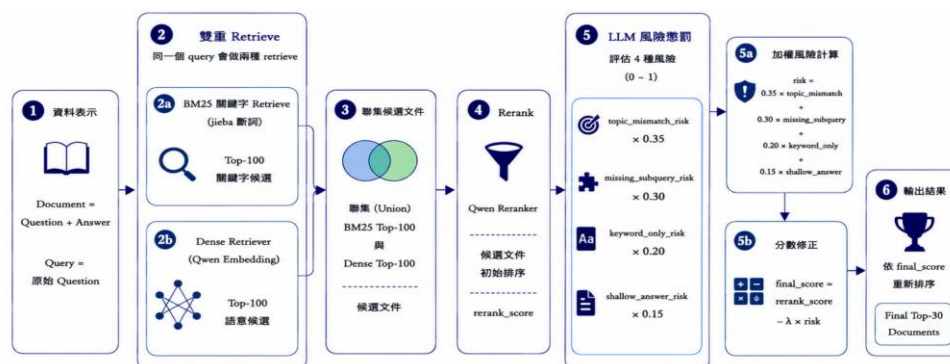
最後，我們加入 LLM 風險懲罰機制，針對候選答案評估四種風險：主題方向錯誤、遺漏重要子問題、只對到關鍵字但沒有真正回答，以及回答過於通用不夠具體。最終分數為 rerank score 減去加權風險分數。實驗結果顯示，當風險懲罰權重 $\lambda = 0.2$ 時效果最佳，Mean Rank 為 2.8（見表格六）。

風險懲罰權重多寡	MAP@10	MAP@30	MRR	NDCG@10	NDCG@30	Mean_rank
無 LLM 風險懲罰	0.6322	0.3856	0.8533	0.7858	0.9119	4.4
LLM風險懲罰權重 = 0.1	0.5953	0.3822	0.8500	0.7645	0.9133	4.8
LLM風險懲罰權重 = 0.2	0.6402	0.3943	1.0000	0.8146	0.9351	2.8
LLM風險懲罰權重 = 0.3	0.5960	0.3710	0.9333	0.7922	0.9300	3.6

表格六：有無LLM風險懲罰的實驗表格

五、Phase 2 方法與結果分析

以下為我們方法的架構圖（見圖二）。我們提交到 Phase 2 的最終方法為 BM25 + Qwen3-Embedding-4B 進行候選召回，將兩者各自檢索出的 Top-100 結果取 union 後，再使用 Qwen3-Reranker-4B 進行重新排序。最後，我們加入 LLM 風險懲罰機制，針對候選答案進行額外檢查，降低雖然表面相似但實際回答不足的候選答案排名，並依照 final score 輸出 Top-30 作為最終檢索結果。



圖二：最終方法架構圖

在 Phase 2 的官方結果中，我們方法的平均排名為第 6.6 名（見表格七）。雖然最終排名未達到內部評估中預期的前段表現，但相較 Phase 1 的結果已經有明顯改善。特別是在 MRR 指標上，我們達到 1.0000，表示對多數 query 而言，系統能夠將一筆高度相關的答案排在非常前面，代表最終方法在「找第一個正確答案」這件事上表現得很好。

Team	MAP@10	MAP@30	MRR	NDCG@10	NDCG@30	Mean Rank
Team 3	0.8669 (3)	0.7419 (1)	1.0000 (1)	0.9570 (1)	0.9079 (1)	1.4
Team 5	0.8829 (2)	0.7323 (2)	1.0000 (1)	0.9552 (2)	0.8955 (2)	1.8
Team 8	0.8870 (1)	0.6482 (5)	0.9500 (6)	0.9527 (3)	0.8369 (6)	4.2
Team 2	0.8329 (5)	0.7035 (3)	0.9500 (6)	0.9401 (4)	0.8798 (3)	4.2
Team 1	0.8588 (4)	0.6476 (6)	1.0000 (1)	0.9366 (6)	0.8452 (5)	4.4
Team 7	0.8292 (7)	0.6769 (4)	0.9500 (6)	0.9385 (5)	0.8636 (4)	5.2
Team 9	0.8293 (6)	0.6257 (7)	1.0000 (1)	0.9308 (7)	0.8270 (7)	5.6
Team 6	0.6236 (8)	0.5150 (8)	1.0000 (1)	0.8109 (8)	0.7681 (8)	6.6
Team 4	0.5688 (9)	0.4290 (9)	0.9000 (9)	0.7902 (9)	0.7236 (9)	9

表格七：Term Project Phase 2 Results

不過從 MAP 與 NDCG 的指標來看，我們的方法仍有改進空間。MRR 表現佳但 MAP 與 NDCG 排名相對較後，代表系統雖然能在前幾名找到相關答案，但 Top-30 整體排序品質仍不夠穩定。這可能與 LLM 風險懲罰的判斷穩定性有關，當風險懲罰能正確辨識候選答案的不足時，可以有效提升排序；但如果 LLM 對部分醫療問題的風險判斷過於保守，則可能將部分原本相關的答案往後移，進而影響整體的排序品質。

此外，我們也將 Phase 1 使用的 ReFIT 方法重新套用到 Phase 2 query 上，並與最終提交方法進行比較（見表格八）。結果顯示，使用 ReFIT 在 Phase 2 中僅取得 Mean Rank = 8.6，而我們的最終方法則為 Mean Rank = 6.6，且所有指標皆優於 ReFIT 的版本。Phase 2 的結果也說明混合式檢索比單純依賴 dense retrieval 更適合此任務。BM25 能有效補足 dense retriever 在字面關鍵詞上的不足；而 Qwen3-Embedding-4B 則能捕捉語意相近但用詞不同的問題；Qwen3-Reranker-4B 負責進一步排序候選答案；LLM 風險懲罰則嘗試從答案是否真的回應問題的角度修正排序。雖然最終結果仍未達到最佳，但相較 Phase 1 已經能看出方法的方向更合理且有進步。

方法	MAP@10	MAP@30	MRR	NDCG@10	NDCG@30	Mean Rank
Qwen3-Embedding-4B + Qwen3-Reranker-4B + ReFIT	0.4324 (9)	0.3873 (9)	0.8500 (9)	0.8069 (8)	0.7432 (8)	8.6
BM25+ Qwen3-Embedding-4B -> union -> Qwen3-Reranker-4B + LLM風險懲罰	0.6236 (8)	0.5150 (8)	1.0000 (1)	0.8109 (8)	0.7681 (8)	6.6

表格八：ReFIT 與最終方法在 Phase 2 Query 上的結果比較

六、結論

我們的專題從 Phase 1 採用的 ReFIT 方法出發，進一步分析其在醫療問答檢索任務中表現不佳的可能原因，並在 Phase 2 中改以混合式檢索與排序修正作為主要改進方向。實驗結果顯示，直接更新 query embedding 並不一定適合此任務。由於醫療問題通常包含症狀、疾病、檢查、治療方式等多層次語意，若更新後的 query embedding 偏離原始問題意圖，反而可能影響後續檢索結果，進而降低整體排序品質。

相較之下，結合 BM25 關鍵字檢索、Qwen dense retrieval、Qwen reranker 與 LLM 風險懲罰機制，能更全面地提升檢索效果。BM25 可補足醫療關鍵詞在字面匹配上的需求，dense retriever 則能捕捉語意相近但用詞不同的候選答案；reranker 能進一步優化候選文件的排序，而 LLM 風險懲罰則從回答品質的角度進行修正，降低表面相似但實際未充分回答問題之候選答案的排名。

我們的方法仍存在一些限制。首先，LLM 風險懲罰雖然能從回答是否切題、是否具體回應問題等角度輔助排序，但其判斷結果仍可能受到 prompt 設計與模型穩定性的影響。然而我們主要使用 Phase 1 的人工標註結果作為內部評估依據，但由於 Phase 1 的標註資料是基於 TREC pooling 產生，並非對完整 corpus 進行標註，因此內部評估結果與官方 Phase 2 評估結果之間可能存在一定落差。

整體而言，Phase 2 的最佳方法相較於 Phase 1 已有明顯改善。從官方結果來看，我們的方法在 MRR 指標上達到 1.0000，表示系統能有效將相關答案排序至前段位置；同時，與 ReFIT 版本相比，最終方法在 MAP、MRR、NDCG 等指標上皆有所提升。這顯示在此任務中，放棄直接更新 query embedding，改採混合式檢索與排序修正，是較為合適且有效的策略。